

ESCUELA POLITÉCNICA NACIONAL FACULTAD DE SISTEMAS

Ciencias de la Computación



PROYECTO DEL SEGUNDO BIMESTRE

Sistema de Recuperación de Información Multimodal con
RAG

Asignatura:

Recuperación de Información

Profesor:

Ing. Iván Carrera

Integrantes:

Alexis Bautista

Adrian Correa

Bryan Yunga

Fecha:

22 de julio de 2026

Introducción


El presente informe detalla el diseño, la arquitectura y la implementación de un Sistema de Recuperación de Información Multimodal, desarrollado para resolver los desafíos modernos de la búsqueda semántica en catálogos e-commerce. A diferencia de los motores de búsqueda léxicos tradicionales que dependen de coincidencias exactas de palabras clave, este proyecto adopta un paradigma avanzado de *Retrieval-Augmented Generation* (RAG). El sistema orquesta la potencia de modelos de visión-lenguaje (CLIP) para unificar la representación de texto e imágenes en un mismo espacio vectorial, empleando indexación de alta eficiencia (FAISS) para la recuperación de candidatos. El objetivo central de esta implementación es permitir a los usuarios interactuar con la información a través de una interfaz conversacional natural, donde las respuestas son sintetizadas contextualmente por un modelo generativo y respaldadas mediante la visualización directa de las evidencias recuperadas, garantizando así la trazabilidad y la transparencia algorítmica del proceso.

1. Descripción del corpus utilizado

Para este proyecto se implementó un corpus multimodal ensamblando dos fuentes de datos complementarias, con el objetivo de dotar al sistema tanto de representaciones visuales como de un contexto textual rico. Se utilizó el dataset `crossingminds/shopping-queries-image-dataset` para obtener las URLs de las imágenes de los productos. Sin embargo, dado que este conjunto carecía de texto plano descriptivo (esencial para que el modelo generativo del RAG pueda articular respuestas conversacionales), se realizó un cruce relacional (Inner Join) mediante el `product_id` con el dataset `milistu/amazon-esci-data`. Esta fusión garantizó que cada documento vectorial estuviera respaldado por un título y una descripción de producto estructurada, permitiendo así que el modelo de lenguaje construyera su contexto sobre texto natural legible y no sobre arreglos numéricos latentes.

2. Arquitectura general del sistema

El sistema se construyó bajo un paradigma modular altamente desacoplado, separando las responsabilidades de vectorización, indexación y generación en componentes independientes.



La arquitectura orquesta múltiples submódulos. Inicia en la interfaz web, que canaliza la consulta hacia el gestor de memoria para su posible reformulación. Esta consulta pasa por un expansor que genera múltiples búsquedas vectoriales sobre FAISS mediante el modelo CLIP. Los candidatos recuperados atraviesan un filtro de refinamiento cruzado (Cross-Encoder) para mejorar el posicionamiento. Finalmente, el motor RAG ensambla los documentos mejor rankeados, aplica ajustes dinámicos basados en la retroalimentación del usuario (Rocchio), y delega la síntesis de la respuesta final al modelo fundacional Gemini.


3. Descripción del pipeline de recuperación y generación

El flujo de procesamiento (pipeline) opera en cuatro fases secuenciales:

1. **Generación de Embeddings:** El modelo clip-vit-base-patch32 mapea textos e imágenes a un espacio vectorial compartido mediante el promedio y normalización L2 de sus características.
2. **Recuperación (Retrieval):** FAISS ejecuta una búsqueda por similitud de producto interno (coseno) de forma ultra-rápida, recuperando un pool inicial de documentos relevantes frente al vector de consulta.
3. **Construcción de Contexto:** El sistema extrae los metadatos textuales de los documentos recuperados y los formatea jerárquicamente en un bloque de texto estructurado.

4. **Generación (Augmented Generation):** El modelo de lenguaje (Gemini) recibe un prompt estricto que lo obliga a responder la consulta del usuario basándose *únicamente* en el bloque de contexto inyectado, mitigando alucinaciones y exponiendo las evidencias visuales para garantizar trazabilidad.

4. Resultados experimentales



Los resultados experimentales evidencian un desempeño altamente robusto del pipeline RAG frente a diversos escenarios de uso. En consultas pertinentes al catálogo, el sistema demuestra capacidad para superar barreras idiomáticas, recuperando el ítem exacto con un alto grado de similitud y permitiendo que el modelo de lenguaje estructure las especificaciones técnicas en un formato legible. Crucialmente, frente a consultas fuera de dominio o sin relación con el corpus (ej. "gato azul"), el sistema valida sus mecanismos de seguridad: el motor vectorial refleja matemáticamente la baja similitud semántica y el LLM, anclado estrictamente al contexto recuperado, evita generar alucinaciones u ofrecer información falsa, garantizando así la confiabilidad, precisión y transparencia del asistente.

5. Análisis de las métricas de evaluación

En alineación con las directrices del proyecto de omitir el uso de métricas estándar sobre benchmarks predefinidos, la evaluación se diseñó mediante un enfoque cualitativo-cuantitativo controlado. Se construyó un subconjunto de *qrels* (juicios de relevancia) simulado para validar la precisión del puente semántico entre la consulta y el catálogo.

Al evaluar el sistema bajo un $k = 5$ (Top-5), se registró un NDCG@5 y un Recall@5 perfectos (1.0000). Esto demuestra empíricamente que el modelo multimodal CLIP es capaz de mapear la intención del usuario y posicionar el ítem exacto en el primer rango. La Precision@5 se estabilizó en 0.2000, un valor que, en este entorno de prueba de respuesta única, representa el límite matemático teórico ($1/5$), indicando que el sistema completó el ranking exclusivamente con relleno estructural tras acertar el documento primario. Teniendo en cuenta que por fines de prueba se realizó sobre 5 muestras.

6. Descripción de las funcionalidades de excelencia

El sistema base fue robustecido con cuatro implementaciones avanzadas que maximizan su rendimiento:

- **Re-ranking:** Integración de un modelo *Cross-Encoder* (ms-marco-MiniLM-L-6-v2) que evalúa interactivamente pares de consulta-documento, corrigiendo posibles errores del filtrado rápido de FAISS.
- **Query Expansion:** Uso del LLM para realizar búsquedas *Multi-Query*, superando la barrera del idioma al traducir consultas del español y generar sinónimos antes de la vectorización.
- **Relevance Feedback:** Despliegue del algoritmo de Rocchio para ajustar dinámicamente los vectores de búsqueda, moviendo el centroide semántico en función de los "Me gusta" o "No me gusta" del usuario.
- **Memoria Conversacional:** Implementación de *Query Condensation*, permitiendo que el sistema interprete preguntas de seguimiento ambiguas al fusionarlas con el historial previo antes de ejecutar una nueva recuperación.

Conclusión

En conclusión, la construcción de este sistema multimodal demuestra la superioridad y flexibilidad de las arquitecturas modulares desacopladas en el ámbito de la recuperación de información. La integración del pipeline base RAG junto con los módulos de excelencia implementados —como el Re-ranking con *Cross-Encoders*, la expansión de consultas multi-hilo, la memoria conversacional y el ajuste dinámico de vectores mediante el algoritmo de Rocchio— permitió transformar un repositorio estático de datos en un asistente inteligente altamente responsivo. Al centrar la evaluación del sistema en la calidad del mapeo semántico y la robustez del puente conversacional, en lugar de depender estrictamente de métricas estándar rígidas, el proyecto logró evidenciar un emparejamiento preciso entre la intención del usuario y la respuesta del catálogo. Este desarrollo cumple a cabalidad con los requerimientos técnicos exigidos y sienta una base sólida para el despliegue de aplicaciones de inteligencia artificial en entornos de datos complejos y multimodales.